



Universidad Nacional Experimental del Táchira

Vicerectorado Académico

Decanato de Docencia

Departamento de Ingeniería en Informática

Trabajo de aplicación profesional

Proyecto especial de grado

PAQUETE EN LENGUAJE R PARA LA CLASIFICACIÓN DE TUBÉRCULOS DE PAPA CRIOLLA (*Solanum
phureja*) PARA DIFERENTES DENSIDADES DE SIEMBRA EMPLEANDO REDES NEURONALES
PROBABILÍSTICAS.

Autor(es): Jesús David Escalante Rodríguez

C.I.: 21.220.841

jesusd.escalante@unet.edu.ve

Tutor(es): Rossana Timaure

rttg@unet.edu.ve

San Cristóbal, Julio.2018

Introducción

En los cultivos de papa criolla (*Solanum phureja*) son muchas las variables que influyen en la cosecha de tubérculos, tales como la temperatura, altura del terreno, clima, tipo y composición del suelo, densidad de siembra, entre otros. Los encargados y personas interesadas en este proceso siempre han buscado manipularlas, no sólo para mejorar la calidad del producto, si no para obtenerlo características que sea convenientes, como el tamaño de los tubérculos ya que existen intereses industriales diferentes para su comercialización.

Investigaciones anteriores concluyeron que la densidad de siembra es una variable con una afectación considerable en el tamaño de los tubérculos producidos por las plantas en su ciclo de cosecha, sin embargo la manipulación de esta variable generalmente se maneja de forma lineal sin tener en cuenta, ciertas condiciones espaciales que posee como propiedades esta variable, por ser distancias entre calles y surcos, y distancia entre plantas a la que se siembra, o expresado de otra manera cuantas plantas son sembradas por metro cuadrado en un terreno.

La densidad de siembra es una variable cualitativa que aunque se trata de distancias se definen en densidades predeterminadas como $d_1 = 50 \times 30 \text{cm}$, donde d_1 es una densidad definida igual a un espacio entre surcos de 50cm y distancia entre plantas de 30cm.

Técnicas.

Las redes neuronales clasifican basado en sus neuronas entrenadas a través de datos conocidos con anterioridad, por lo que no es de importancia el hecho de que no exista una relación entre estas variables, ya que no requiere de supuestos estadísticos a tener en cuenta para su proceso de clasificación.

El uso de redes neuronales probabilísticas es una solución que se plantea usar en la siguien-

te propuesta para el modelado de los datos recogidos y observados de la cosecha de un cultivo de tubérculos de papa criolla (*S. phureja*) realizado en el Centro Agropecuario Marengo de la Universidad Nacional de Colombia, en el departamento de Cundinamarca en Colombia ($74^{\circ}12'58.51''\text{W}$; $4^{\circ}40'52.92''\text{N}$), el cual tiene una altitud de 2516 msnm y una temperatura media de 14°C . Implementado como un paquete en Lenguaje R que permita a través de una entrada, propuesta como una matriz cargada con los datos observados de cultivo, clasificar los tubérculos de papa criolla cosechados en densidades de siembra según el peso total del cultivo, peso total de tubérculos y diámetro de cada tubérculo.

Este anteproyecto de trabajo de grado está dividido en los siguientes capítulos:

Capítulo 1. Preliminares.

- Planteamiento del Problema; en él se plantean las razones en las cuales esta basado el proyecto de investigación.
- Objetivos, se expone el objetivo general del proyecto de investigación y se identifican los objetivos específicos mediante los cuales se lleva a cabo el desarrollo del proyecto.
- Justificación e importancia, se establecen los motivos por cuales el desarrollo del proyecto de investigación es relevante
- Alcance y limitaciones, se detalla la funcionalidad del proyecto de investigación.

Capítulo 2. Fundamentos teóricos

- Antecedentes, se exponen revisiones de investigaciones previas que posean relación directa con el tema del actual proyecto de investigación.
- Bases teóricas, se definen un conjunto de conceptos que proporcionan conocimiento acerca del objeto de estudio.

Capítulo 3. Fundamentos metodológicos

- Enfoque de la investigación, se plantea el enfoque utilizado para llevar a cabo la investigación.
- Tipo o nivel de investigación, se expone el tipo de investigación y nivel de investigación, según el grado de profundidad que abarca y la naturaleza de los datos.
- Diseño de la investigación, se establece la estrategia general que adopta el investigador para responder al problema planteado.

- Metodología, se describen el conjunto de técnicas, herramientas y pautas utilizadas para llevar a cabo el proyecto de investigación.

Capítulo 1

Preliminares

1.1. Planteamiento y formulación del problema

La producción de papa criolla (*S. phureja*), siempre ha tenido muchos desafíos por parte de la industria, debido a los grandes intereses provenientes de los diferentes consumidores que la misma posee, siendo así que es uno de los productos agrícolas mas consumidos y con mayor importancia en el mundo, después del arroz, el maíz y el trigo. Colombia es el mayor productor de papa criolla en Latinoamérica y por lo cual es un país que posee grandes exigencias industriales para su producción (Ligarreto *et al.*, 2003).

Los tubérculos de papa criolla tienen un tamaño aproximado entre dos y ocho centímetros (2-8 cm), y se pueden clasificar en tres calibres según su diámetro transversal promedio, de donde radican los intereses comerciales de la misma. Los tubérculos de entre dos y medio y cuatro centímetros son preferidos para encurtidos y pre-cocidos mientras los tubérculos promedio entre cuatro y seis y medio centímetros son preferidos para frituras en hojuelas o con mas de cinco centímetros para frituras en tiras (CORPOICA, 2009).

El crecimiento vegetal es definido como el aumento irreversible del tamaño y peso seco de las plantas (altura, área foliar, diámetro, número de células y cantidad de protoplasma) o los cambios que ocurren en una planta o población de plantas a través del tiempo, fenómeno acompañado del aumento en la complejidad estructural metabólica del organismo (diferenciación celular, número de hojas), por procesos de división y alargamiento celular, incorporación de materia y energía del ambiente (fotosíntesis, absorción de agua y de iones) y metabolización subsiguiente (Cabezas 2005), la cual se traduce en multiplicación y diferenciación celular. Este proceso está íntimamente

relacionado con algunos factores internos como fotosíntesis, respiración, transpiración, condiciones de estrés, concentración enzimática, balance hormonal y expresión genética (Piñeros, 2009).

En la papa son dos los procesos fisiológicos asociados directamente al rendimiento de la misma, la fotosíntesis y la respiración. Y estos dos son procesos íntimamente asociados, ya que durante la fotosíntesis se producen carbohidratos que son consumidos durante la respiración, pero una gran cantidad de estos carbohidratos contribuyen al proceso de producción incrementando el tamaño de los tubérculos, el nivel y periodo de crecimiento de los tubérculos es una variable que responde directamente a la expresión de rendimiento expresada como producción por día, siendo así que cerca de un noventa por ciento (90 %) del peso acumulado de los tubérculos producidos por una planta es producto de la asimilación de dióxido de carbono, así como otros procesos similares (Beukema, 1979). Sin embargo, estos procesos se ven afectados por condiciones externas tales como la intensidad de luz, temperatura, longitud de los días, condiciones del suelo que son variables no controladas, o por condiciones como la cantidad de riego, fertilizantes aplicados para la mejora de los suelos que son variables controlables pero que requieren de costos adicionales de producción (Piñeros, 2009). Es por ello que se sigue buscando, con el manejo de variables controladas, el control sobre la cantidad total producida y el tamaño de los tubérculos, sin producir costos adicionales, siendo la densidad de siembra una de estas variables, en la cual nos enfocaremos en esta investigación (Bernal, 2017).

Sin embargo, la densidad de siembra es una variable de tipo espacial, ya que se define como la distancia entre plantas y entre linderas, siendo así una coordenada en X - Y en un plano cartesiano, por lo cual un estudio estadístico de la misma para clasificar o predecir un modelo no puede ser del tipo de regresión lineal o de un análisis de varianza, debido a que los supuestos de estos modelos establecen que los residuales deben ser independientes en cada punto, no tomando en cuenta una relación entre vecinos, como si ocurre en los cultivos de papa, las plantas compiten por los recursos y por consiguiente por producir más, haciendo así los residuales dependientes (Piñeros, 2009).

La identificación siempre ha sido un problema de interés en el área agrícola, existen trabajos sobre la identificación de variedades de papas, sobre la capacidad de las plantas de papas para cobertura del suelo entre otras variables de estudio sometidas a clasificación, esto debido al impacto que tiene la comercialización y manejo agrícola del producto, entre las técnicas empleadas se encuentran modelos estadísticos basados en probabilidad, las máquinas de soporte vectorial y las redes neuronales, estas últimas técnicas presentan la ventaja de que bajo el proceso de aprendizaje supervisado no presentan supuestos rígidos en cuanto al comportamiento y relación de los datos

de entrada (Pal, 2003; Aziz 2016).

Una red neuronal artificial (*artificial neural network*, ANN) es un modelo que crea una relación entre una configuración de señales de entrada y una señal de salida usando un modelo derivado de nuestro entendimiento de como el cerebro responde a determinados estímulos de entradas sensoriales. Así como un cerebro usa ese conjunto de células interconectadas llamadas neuronas, así las ANN usan una red de neuronal artificiales o nodos para solucionar problemas aprendidos (Lantz, 2015).

En general, las ANN son aprendices versátiles que pueden ser aplicadas a casi cualquier tarea de aprendizaje en cualquier contexto, clasificación, predicción, reconocimiento de patrones e incluso de tareas de supervisión de procesos. Las ANN, se aplican mejor a los problemas cuyos datos de entrada y salida son bien definidos o bastante simples, sin embargo el proceso que relaciona la entrada con una determinada salida es en extremo complejo, por eso se conocen como un método de caja negra (Lantz, 2015).

Las ANN han sido usadas desde hace cincuenta años para simular como el cerebro humano es capaz de resolver problemas. Primero surgieron las simples funciones lógicas AND y OR, que ayudaron a los científicos a entender como biológicamente el cerebro opera. Sin embargo, como el avance tecnológico y computacional ha sido incrementado y continua creciendo potencialmente durante los últimos años, las ANN ha incrementado su complejidad siendo usadas frecuentemente en múltiples problemas como:

1. Programas de reconocimiento de voz y escritura, como los que usan los correo de voz de los servicios de transcripción y máquinas clasificadoras de correo postal.
2. La automatización de dispositivos inteligentes como los controles ambientales de un edificio de oficinas o automóviles autoguiados y drones autoguiados.
3. Modelos sofisticados de patrones climáticos y otros fenómenos científicos, sociales o económicos.
4. La clasificación y reconocimiento de cualquier tipo de frutos y hojas de plantas, basado en sus atributos y características.

Las redes neuronales probabilísticas (*Probabilistic neural network*, PNN) se derivan de las ANN y se diferencian en que estas hacen uso de redes de funciones de base radial. Son adoptadas en

muchos casos por su fácil entrenamiento y velocidad de análisis. Las PNN tienen tres capas, una primera de entrada, una de base radial y otra de competición. Básicamente la capa de base radial evalúa las distancias entre los valores de un vector de entrada y estas distancias son escaladas no linealmente, para que la capa de competitividad encuentre la distancia mas corta , a través de la cual realiza la clasificación.

R es un lenguaje de programación y entornos para gráficos y cálculos estadísticos, es una implementación diferente al lenguaje S (Chambers, 1998), y se desarrolla bajo un proyecto de *software* bajo Licencia Pública General (*General Public License*, GNU) de la *Free Software Foundation* (<https://www.fsf.org/>) en forma de código fuente. Se compila y se ejecuta en una amplia variedad de plataformas entre ellas *FreeBSD*, *Linux*, *Windows* y *MacOS*. (The R Project for Statistical Computing, 2018).

Esta propuesta tiene como objetivo desarrollar un paquete en lenguaje R que permita ajustar y entrenar una red neuronal artificial probabilística para la clasificación de densidades de siembra de papa criolla (*Solanum Phureja*) teniendo como entrada las siguientes variables:

1. **Peso total del cultivo.** Variable cuantitativa expresada en gramos (g/cosecha), que indica el peso de todos los tubérculos recogidos en la siembra.
2. **Total de tubérculos recogidos.** Variable cuantitativa que indica el número/cosecha de tubérculos recogidos en la siembra.
3. **Diámetro ponderado de todos los tubérculos.** Variable cuantitativa expresada en centímetros (cm.), que indica el calculo del diámetro ponderado (por los tubérculos ser ovoides) de cada tubérculo recogido en la siembra.

Esta herramienta permitirá entre otras cosas a investigadores del área agrícola y a bioestadísticos comparar los resultados de clasificación alimentando la red con datos observados y con los mismos datos normalizados especialmente a través de regresión espacial, para observar si es necesario el análisis de los datos recogidos antes de la clasificación y a su vez concluir hasta que punto la densidad de siembra afecta las variables antes mencionadas. Otra de las pruebas que se plantea usar en esta investigación es realizar los análisis eliminando variables de entrada atisbando cuales variables permiten y generan una mejor clasificación.

1.2. Objetivos

1.2.1. Objetivo General

Desarrollar un paquete en lenguaje R que permita la clasificación de tubérculos de papa criolla (*S. phureja*) para diferentes densidades de siembra empleando redes neuronales probabilísticas.

1.2.2. Objetivos Específicos

- Estudiar la parametrización de la densidad de siembra como parámetro de entrada al clasificador
- Diseñar los algoritmos para las funciones principales que permitan el entrenamiento de una red neuronal probabilística para la clasificación de tubérculos de papa criolla (*S. phureja*) para diferentes densidades de siembra.
- Implementar las funciones para la clasificación de tubérculos de papa criolla para diferentes densidades de siembra, basadas en los algoritmos desarrollados.
- Realizar la pruebas del paquete desarrollado bajo diferentes escenarios.

1.3. Justificación e Importancia

Colombia es el mayor productor, consumidor y exportador de papas diploides en el mundo; tiene una ventaja competitiva notable debido a ser centro de diversidad y poseer gran aceptación por los consumidores debido a las características del tubérculo. Adicionalmente, en este país se ha desarrollado una amplia tradición como cultivo tecnificado, con potencial de industrialización y exportación (Rodríguez *et al*, 2009). Además de contar con uno de los recursos genéticos que ofrece las mayores oportunidades de exportación como alimento procesado exclusivo y sin competencia. Desafortunadamente, muchas de las estrategias de manejo del cultivo de la papa, han sido adaptadas a papa criolla (*S. phureja*), creando un sistema productivo poco eficiente (Piñeros, 2009). Los altos precios de los insumos agrícolas y el mal manejo de los cultivos agrónomicamente provoca baja productividad y amenaza la competitividad del sistema de producción, por lo que es importante identificar factores limitantes del rendimiento y desarrollar prácticas innovadoras para el cultivo, tales como una gestión nutricional integrada y equilibrada, que es una de las prácticas más eficientes para garantizar a la planta la oportunidad de expresar su potencial genético que

eventualmente se reflejara en una mejor calidad y rendimiento (López *et al*, 2014).

Varias investigaciones revelan que el tamaño promedio de los tubérculos, su variabilidad y su conteo, definen una única distribución, presentando mayor variabilidad de rangos de tamaño en la etapa final de llenado, con aumento del rendimiento de los mayores tamaños por cuenta de los tamaños inferiores, lo que sugiere que un tubérculo que pasa de un calibre inferior al siguiente, no es sustituido por otro de calibre anterior, además, parece existir una correlación negativa entre la variabilidad relativa del tamaño del tubérculo y el número de tubérculos por unidad de área (Struik, 1991).

Es importante reconocer, que debe tenerse cuidado con la interpretación de esta correlación, pues hasta cierto punto, la naturaleza de los datos asociados al número de tubérculos por planta pudiera ser similar a la de los datos composicionales, es decir, si un componente aumenta, el otro esta forzado a disminuir, lo que genera correlaciones sin conexión lógica en datos verdaderamente composicionales, sin embargo, el número de tubérculos por calibre no suma una constante, pudiera ocurrir que su máximo posea una distribución específica, entonces una mayor cantidad de tubérculos de un calibre podría provocar un número menor de tubérculos en otro calibre específico, lo que en esencia puede generar correlaciones en las que debe tenerse mucho cuidado al momento de su interpretación.

La importancia del cultivo obliga a muchos investigadores a realizar diferentes estudios para mejorar la práctica agrícola, la descripción y clasificación de las variables que impacten en el estudio del crecimiento de los tubérculos, ya que de eso depende el uso a darles; procurando siempre hacer uso del espacio de siembra de forma óptima, por lo que varios estudios evidencian el estudio de la densidad de siembra para evaluar sobre todo el rendimiento. En Bernal(2017) evaluó en lugar del rendimiento, un indicador que se asocia directamente como lo es el calibre de los tubérculos, los cuales en la práctica se manipulan en cuatro categorías de diámetro promedio (hasta 2 cm, de 2 a 4 cm, de 4 a 6 cm y más de 6 cm). La naturaleza de esta variable imposibilita usualmente la comparación de la respuesta (conteos de tubérculos) para cada densidad de siembra (definidas como 30cm*100cm, 40cm*100cm y 50cm*100cm) mediante análisis de varianza, pues en el caso de conteos, otras distribuciones como la Poisson y la Binomial negativa se adaptan mucho mejor al tipo de dato generado. Los modelos clásicos de regresión Poisson y binomial y negativa, en sus modalidades usuales o en la opción inflada por ceros (Cameron, 1998) en datos de conteo pertenecen a la familia de modelos lineales generalizados (Zeileis, 2008) y los desarrollos recientes permiten generar varias estadísticas que permiten su comparación con sus contrapartes sin ceros en exceso,

lo que resulta útil en la elección del mejor modelo para relacionar predictores y respuesta en conteos.

Sin embargo, los estudios realizados hasta ahora son todos haciendo suposiciones del tipo lineal y haciendo modificaciones que permitan así su estudio a través de ANOVA o regresión lineal tomando en cuenta los patrones de vecindad, más la propuesta consiste en clasificar los datos a través de una red neuronal que no amerita de suposiciones estadísticas o matemáticas, que sólo aprendiendo de lo observado es capaz de realizar una clasificación, a partir de la información existente de la relación latente entre de densidades de siembra y el tamaño del tubérculo, que como herramienta descriptiva pueda ayudar a la planificación de los procesos de siembra.

Además dado que la PNN se desarrollará en lenguaje R, cuyo paradigma es de código abierto y colaborativo, esta investigación permitirá desarrollar una herramienta computacional y estadística que sea escalable a la incorporación de nuevas funciones.

1.4. Alcance y limitaciones

La red neuronal artificial probabilística a implementar tiene como propósito la clasificación de la densidad de siembra en papa criolla (*S. phureja*), siendo útil para incrementar las posibilidades de obtener un determinado y deseado calibre de tubérculos conociendo la densidad a la que se debe sembrar. Las pruebas se realizarán bajo un conjunto de datos reales que fueron tomados bajo las medidas de cuatro calibres de tubérculos y tres densidades de siembra.

Los datos disponibles del cultivo de papa criolla (*S. phureja*), se tienen en base a tres densidades de siembra, cantidad de plantas sembradas, cantidad de tubérculos recogidos, peso total del cultivo, diámetro ponderado de cada tubérculo y calibre de los tubérculos y forman parte de la investigación de Maestría del estudiante de la Universidad Nacional de Colombia, Bernal(2017).

Los resultados de las pruebas sobre los escenarios planteados serán validados estadísticamente con ayuda del análisis de las curvas ROC, y el paquete se distribuirá durante su etapa de desarrollo y pruebas en un repositorio local, y se desarrollara siguiendo las especificaciones y estilos de programación establecidos para el desarrollo de extensiones en R al igual que su documentación.

Capítulo 2

Fundamentos teóricos

2.1. Antecedentes

En el año 2011, Mayabiro E. presento en la Universidad Nacional Experimental del Táchira, un prototipo sobre el entorno MATLAB para el cálculo de la tasa de germinación de plántulas de pimentón previamente segmentadas. El entorno desarrollado permitió establecer una clasificación de las plántulas, hojas u objetos de la misma por medio de redes neuronales. Se realizo el entrenamiento de múltiples redes neuronales multicapas con algoritmos de retropropagación, donde aunque variaban las capas intermedias de las redes y sus funciones de transferencia fueron entrenadas con los mismos datos de entrada, validandolas con una base de datos de pruebas para seleccionar al final una con salidas similares a las deseadas.

La clasificación por medio de redes neuronales ha sido un hito ya marcado en el campo agronómico, muchos estudios se han realizado con el objetivo de analizar ciertos comportamientos de plantas y los beneficios que se puedan sacar de ellas. En el año 2011, el grupo de investigación de sistemas de procesamiento y control de señales de la Universidad Nacional Tenaga de Malasia desarrollo un sistema de inteligencia con un enfoque novedoso para la clasificación de frutas usando técnicas de procesamiento de imágenes digitales y redes neuronales artificiales, con el objetivo de desarrollar un método de clasificación rápido con una meta del 100 % de eficiencia. El estudio se realizo con cinco frutas, manzanas, platanos, zanahorias, mangos y naranjas, extrayendo de ellas siete características en función de la forma y el color. La captura de las imágenes se realizo con una cámara digital convencional y las manipulaciones a los datos y construcción de la red con el software MATLAB. Los resultados obtenidos durante esta investigación fueron de gran avance en el campo de reconocimiento de patrones en imágenes.

Otro estudio realizado en el año 2013 por Stephen Gang Wu consistía en el estudio teórico de técnicas de procesamiento de imágenes y datos para el reconocimiento automático de hojas para la clasificación de plantas. Doce características de las plantas fueron extraídos y distribuidas en cinco variables principales que constituían el vector de entrada de una red neuronal artificial probabilista, que había sido entrenada con 1800 hojas para clasificar 32 tipos de plantas con una precisión superior al 90 %, el autor asegura que su metodología de implementación de la PNN era fácil y rápida en comparación de otras investigaciones similares.

En el año 2017, Bernal N realizó un estudio de campo con el cultivo de papa criolla para evaluar la influencia de la densidad de siembra asociada a distancias entre plantas de 30,40 y 50 cm y distancias entre surcos de 100 cm sobre el conteo de tubérculos de calibres inferiores a 2 cm, entre 2 y 4 cm, entre 4 y 6 cm, y de mas de 6 cm de diámetro ponderado y sobre el peso fresco en gramos de los tubérculos. Los tubérculos cosechados se clasificaron y contaron mediante tamizado y se pesaron en su totalidad sin discriminar por calibre. Los modelos estadísticos empleados para modelar el comportamiento de la cosecha, evidenciaron el efecto significativo de la densidad de siembra sobre el conteo de tubérculos y calibre y se observó una razón aproximada de 40:40:20:1 desde el calibre menor al mayor. El efecto de la competencia, en todos los modelos probados resultó significativo, aumentando en la mayoría de los casos a medida que disminuía la distancia entre plantas, tanto en el patrón de vecindad intrahileras como en el caso de inter e intrahileras.


2.2. Bases Teóricas

2.2.1. Papa criolla (*Solanum Phureja*).

Las variables que influyen en el rendimiento de la papa pueden ser observados en la figura 2.1 2.1. Pag.13.

2.2.2. Redes neuronales artificiales.

Una red neuronal artificial, es un conjunto de nodos de un programa (neuronas) interconectados entre si, simulando el proceso de pensamiento humano, se pudiera considerar como una caja negra entrenada previamente para esperar una entrada y basado en las características o comportamiento de la misma proporcionar una determinada salida, eliminando así la necesidad de diferentes

Figura 2.1: Variables de influencia sobre el rendimiento de *Solanum Phureja*.

algoritmos que deban analizar comportamientos cada uno por separado. Una red neuronal probabilística (PNN) no es mas que una ANN que usa funciones estadísticas que escalan la variable no linealmente como una forma de campana o una distribución normal (Stephen, 2007).

Entre las definiciones más recientes de inteligencia artificial se expresa, en forma general, la inteligencia artificial como la capacidad que tienen las máquinas para realizar tareas que en el momento son realizadas por seres humanos; otros autores como Nebendah (1988) y Delgado (1998) dan definiciones más completas y las definen como el campo de estudio que se enfoca en la explicación y emulación de la conducta inteligente en función de procesos computacionales basados en la experiencia y el conocimiento continuo del ambiente. Autores como Marr (1977), Mompin (1987), Rolston (1992), en sus definiciones involucran los términos de soluciones a problemas muy complejos.

El nacimiento de la inteligencia artificial se sitúa en los años cincuenta; en esa fecha la informáti-

ca apenas se había desarrollado, y ya se planteaba la posibilidad de diseñar máquinas inteligentes. Hoy en día se habla de vida artificial, algoritmos genéticos, computación molecular o redes neuronales. En algunas de estas ramas los resultados teóricos van muy por encima de las realizaciones prácticas.

A través de los años, se han utilizado diversas técnicas de inteligencia artificial para emular 'comportamientos inteligentes'. Al software que hace uso de dichas técnicas se le denomina, de forma genérica, 'sistema inteligente', y es cada vez más amplia la gama de aplicaciones financieras donde incide la inteligencia artificial.

Un ejemplo de esto es que al usarse una tarjeta de crédito, suelen acumularse datos sobre patrones de consumo que después se venderán a diversas empresas. Sobre la base de los pagos efectuados en dicha tarjeta de crédito, los bancos e instituciones de crédito irán elaborando un historial del usuario, el cual se utilizará para autorizar una transacción, para decidir cuándo extender el crédito y para detectar fraudes. Este tipo de procesos requiere de chequeos que suelen resultar bastante complejos, además del uso de criterios variables para poder tomar una decisión final en torno a la autorización de una cierta transacción. Claro que, al manejar enormes volúmenes de información, como los aproximadamente 16 millones de transacciones que Visa Internacional debe verificar diariamente, no resulta nada fácil poder detectar un fraude. Aunque es evidente la necesidad de automatizar procesos como éste, no es del todo obvio incorporar el comportamiento inteligente del ser humano a un programa de computadora que reemplace a un evaluador humano, ya que los sistemas de inteligencia artificial se toman como herramientas de apoyo analítico para el evaluador, mas no como una unidad autosuficiente que por sí sola pueda tomar decisiones.

Las redes neuronales artificiales son eficientes en tareas tales como el reconocimiento de patrones, problemas de optimización o clasificación, y se pueden integrar en un sistema de ayuda a la toma de decisiones, pero no son una panacea capaz de resolver todos los problemas: todo lo contrario, son modelos muy especializados que pueden aplicarse en dominios muy concretos.

Las redes neuronales emulan la estructura y el comportamiento del cerebro, utilizando los procesos de aprendizaje para buscar una solución a diferentes problemas; son un conjunto de algoritmos matemáticos que encuentran las relaciones no lineales entre conjuntos de datos; suelen ser utilizadas como herramientas para la predicción de tendencias y como clasificadoras de conjuntos de datos. Se denominan neuronales porque están basadas en el funcionamiento de una neurona biológica cuando procesa información.

2.2.3. Curvas ROC.

Una amplia gama de tests diagnósticos reportan sus resultados cuantitativamente, utilizando escalas continuas. El análisis de curvas ROC (*receiver operating characteristic curve*) constituye un método estadístico para determinar la exactitud diagnóstica de estos *tests*, siendo utilizadas con tres propósitos específicos: determinar el punto de corte de una escala continua en el que se alcanza la sensibilidad y especificidad más alta, evaluar la capacidad discriminativa del test diagnóstico y comparar la capacidad discriminativa de dos o más *test* diagnósticos que expresan sus resultados como escalas continuas.

2.2.4. Lenguaje R.

R es un conjunto integrado de *software* de código abierto para el almacenamiento, manipulación, cálculo y visualización de datos para computación y gráfica estadística, puede ser compilado y ejecutado en Windows, Mac OS X y otras plataformas UNIX (como Linux), se distribuye usualmente en formato binario (<https://www.r-project.org/about.html>, 2018). El proyecto de *software* R fue iniciado por Robert Gentleman y Ross Ihaka. El lenguaje fue influenciado por lenguaje S desarrollado originalmente en *Bell Laboratories* por John Chambers y sus colegas. Desde entonces ha evolucionado para el cálculo estadístico asociado a diversas disciplinas para contextos académicos y comerciales. En R, la unidad fundamental de código compartible es el paquete, el cual agrupa código, datos, documentación y pruebas, y resulta simple de compartir con otros. Para enero del 2015 ya habían más de 6.000 paquetes disponibles en la Red Integral de Archivos de R, conocido comúnmente por su acrónimo CRAN, el cual es el repositorio de paquetes . Esta gran variedad de paquetes es una de las razones por las cuales R es tan exitoso, pues es probable que algún investigador o académico ya haya resuelto un problema en su propio campo usando esta herramienta, por lo que otros usuarios simplemente podrán recurrir a ella para su uso directo o para llamarla en un nuevo código (Wickham,2015).

2.2.5. Estructura de paquetes en R/RStudio.

Requerimiento del núcleo (*core*)

1. DESCRIPTION: metadatos del package .

La tarea del archivo *Description* es de gran importancia ya que es en el donde se registra la metadata, las dependencias que utiliza el paquete, la licencia y el soporte en caso de ocurrir errores con el mismo La estructura mínima para realizar un paquete en R es la siguiente:

- Package: mypackage
- Title: What The Package Does (one line, title case required)
- Version: 0.1
- Authors@R: person("First", "Last", email = "first.last@example.com",
role = c("aut", "cre"))
- Description: What the package does (one paragraph)
- Depends: R (\geq 3.1.0)
- License: What license is it under?
- LazyData: true

2. [R/](#): dirección del repositorio donde se encuentra el código del paquete (.R files).

Se expondrán las buenas prácticas a la hora de realizar todo nuestro código en R, desde organización de las funciones, estilos de código y nombre de variables

Organizar funciones en R: aunque puedes organizar los archivos como desees, los dos extremos son malos no colocar todas las funciones en el mismo. archivo y no crear un archivo para para función, aunque si una función es muy grande o tiene mucha documentación se puede dar el caso, los nombres de los archivos tienen que ser significativo y deben de terminar en R

- Bien
 - fit_models.R
 - utility_functions.R
- Mal
 - foo.r
 - stuff.r

Se puede recomendar de acuerdo al número de función utilizar prefijo

Nombres de Objetos: Los nombres de las Variables y funciones deben de ser en minúsculas, usar el guión bajo (_) para separar palabras

- Bien
 - day_one

- day_1
- Mal
 - first_day_of_the_month
 - DayOne
 - dayone
 - djm1

En lo posible no usar nombres de variables existentes esto causará confusión.

Espaciado: Se recomienda colocar espacios alrededor de todos los operadores lógicos y aritméticos (=, +, -, <-, etc.). siempre coloque un espacio después de una coma, y nunca antes de ella.

- Bien
 - average <- mean(feet / 12 + inches, na.rm = TRUE)
- Mal
 - average<-mean(feet/12+inches,na.rm=TRUE)

Hay una pequeña excepción a esta regla: (:, :: y :::) no necesitan espacios alrededor de ellos.

- Bien
 - x <- 1:10
 - base::get
- Mal
 - x <- 1 : 10
 - base :: get

Dejar un espacio antes del paréntesis izquierdo, excepto en la llamada a una función

- Bien
 - if (debug) do(x)
 - plot(x,y)
- Mal
 - if(debug)do(x)

- `plot(x, y)`

Se Utiliza mas de un espacio es caso que de mejore a la alineación, por ejemplo:

```
list(
    total  = a + b + c,
    mean   = (a + b + c) / n
)
```

No coloque espacios alrededor del código entre paréntesis o corchetes (a menos que haya una coma)

■ Bien

- `if (debug) do(x)`
- `diamonds[5,]`

■ Mal

- `if (debug) do(x)` *# no espacios alrededor de debug*
- `x[1,]` *# necesita un espacio despues de la coma*
- `x[1 ,]` *# el espacio va despues de la coma no antes*

Llaves: Una llave de apertura nunca debe ir en su propia línea y siempre debe ir seguida de un nueva línea. Una llave siempre debe ir en su propia línea, a menos que sea seguida por otra y siempre sangría el código dentro de las llaves

■ Bien

- ```
if (y < 0 && debug) {
 message("Y es negativo")
}
```
- ```
if (y == 0 ) {
    log(x)
} else {
    y ^ x
}
```

- Mal
 - ```
if (y < 0 && debug)
 message("Y es negativo")
```
  - ```
if (y == 0) {
  log(x)
}
else {
  y ^ x
}
```

Sentencias muy cortas se bien dejarla en la misma línea.

`if(y < 0 && debug) message("Y es negativo")`

Longitud de Línea: cada línea debe de llevar máximo 80 caracteres, si se queda sin espacio es recomendable utilizar una función separada

Sangría: Utilice sangría de 2 espacios, nunca use tabulador o multiples tabuladores o espacios. la única excepción es cuando se define una sentencia en multiples líneas.

```
long_function_name <- function(  a = "a long argument",
                                b = "another argument",
                                b = "another argument",
```

Asignación: Usar el `<-`, y no `=`

- Bien
 - `x <- 5`
- Mal
 - `x = 5`

3. man/: documentación.

4. NAMESPACE: especifica que objetos conforman el paquete.

Comentarios: Comente tu código, el comentario comienza #, los comentarios deben de explicar el porque, no el que.

use los caracteres (-) y (=) para separar líneas

```
# Load data - - - - -
```

```
# Plot data - - - - -
```

2.2.6. RStudio.

RStudio es un ambiente de desarrollo integrado (*Integrated Development Environment*, IDE) que ofrece herramientas de desarrollo vía consola, editor de sintaxis que apoya la ejecución de código, así como herramientas para el trazado, la depuración y la gestión del espacio de trabajo. RStudio está disponible para Windows, Mac y Linux o para navegadores conectados a RStudio Server o RStudio Server Pro (Debian / Ubuntu, RedHat / CentOS, y SUSE Linux) (<https://www.rstudio.com/about/>, 2018).

Capítulo 3

Fundamentos Metodológicos

A continuación se plantea la estructura a seguir por el presente trabajo, detallando el enfoque, tipo, nivel y diseño de la investigación y la metodología a implementar entre otros.

3.1. Enfoque de la investigación

En función de los objetivos planteados en la presente investigación, la misma se adecua a los parámetros de una investigación de tipo proyectivo. La Universidad Pedagógica Experimental Libertador UPEL (2006) expone que la investigación proyectiva consiste en encontrar la solución a los problemas prácticos, se ocupa de cómo deberían ser las cosas para alcanzar los fines y funcionar adecuadamente. Consiste en la elaboración de una propuesta o de un modelo, para solucionar problemas o necesidades de tipo práctico, ya sea de un grupo social, institución, un área en particular del conocimiento, partiendo de un diagnóstico preciso de las necesidades del momento, los procesos explicativos o generadores involucrados y las tendencias futuras.

3.2. Diseño de la investigación

El diseño de la investigación es la estrategia general que adopta el investigador para responder al problema planteado, por lo que es vital establecer una correcta secuencia de pasos para elaborar el prototipo de software que dará solución a la problemática principal de la investigación Arias(2012).

3.3. Fases metodológicas

3.3.1. Desarrollo del paquete en R

Los pasos a seguir en el desarrollo de esta investigación serán descritos a continuación siendo basados en los antecedentes y estudios realizados y las pautas estándar establecidas para la creación de paquetes y extensiones en R.

Creación del esqueleto del paquete.

En esta etapa se diseñaran y crearan los directorios, ficheros y objetos que conformaran el paquete.

Registrar el método para el envío y uso de funciones.

Es esta etapa del desarrollo se establecerán las dependencias sobre los paquetes de la base fuente de código R y sus métodos de conexión, considerando el manejo de versiones y los criterios de mantenimiento, además se establecerán los espacios de nombre o las estrategias para la búsqueda y utilización de las variables; unificando estos criterios a las funciones que serán diseñadas.

Diseño y codificación de las funciones.

Los métodos para el diseño de las funciones primarias en R serán los diagramas de flujo; y para su codificación se seguirán las normas de estilo para codificación en R, sugeridas por Wickham (2015) y por el creador del paquete *formatR* Xie(2017), además se establecerán la dependencia con las funciones de código base y las recomendadas para desarrollo en R.

Explorar y manipular la data.

Los datos tomados de la investigación de Bernal(2017), son datos reales observados de un cultivo de tubérculos de papa criolla que no han sido tratados estadísticamente o modelados, es por eso que en esta etapa se diseñara un algoritmo para la carga de los mismos en estructuras de datos en R.

Diseñar y entrenar la red neuronal probabilística.

En esta etapa se definirán las variables de entrada y se declararan las neuronas patrones y las clases de salida que permitirán la clasificación, para proceder con el entrenamiento de la red que

se hará a través del método de *jackknifing* para determinar el parámetro de escalamiento correcto que permita la mejor clasificación.

Pruebas unitarias de las funciones.

Debido a que los paquetes en R están conformados, entre otros elementos por las funciones primarias, a cada una de ellas se les realizarán pruebas unitarias en dos fases, la primera con datos sintéticos que permitan comprobar cada estado del diagrama de flujo, que esquematiza la solución numérica y/o lógica que permite la construcción de a PNN y su entrenamiento. Entre las herramientas a utilizarse se encuentran los paquetes de *RUnit* (Zenka, 2015) y *testthat* (Wickham, 2017), y la segunda etapa donde se realizarán las pruebas funcionales del paquete con el conjunto de datos de prueba que formarán parte integral del paquete y con los cuales se desarrollarán los ejemplos prácticos que conformarán la documentación que acompaña al paquete R.

Implementar y realizar pruebas de clasificación.

El objetivo de esta etapa es definir los casos de entrenamiento y prueba que serán usados para buscar la mejor clasificación de densidad de siembra de tubérculos de papa criolla ante diferentes escenarios.

Chequear la carga del paquete.

En esta etapa del desarrollo se utilizarán las funciones de chequear paquete que ofrece el código R; cuya finalidad es verificar cada fichero del árbol de carpetas asociadas a cada elemento de la estructura o esqueleto del paquete, que a su vez creará el archivo de documentación en LaTeX y/o HTML, compilará el código fuente y creará las librerías de enlace dinámico (*dynamic link library* DLL).

Construcción del método de distribución del paquete.

Se seleccionará la forma de distribución del paquete desde el repositorio local, creando los ficheros fuentes (en formato *tarball*) y en binario.

3.3.2. Comparación de resultados.

En este paso se procederá a la construcción de las curvas ROC asociadas a los casos de prueba planteados para el paquete desarrollado, permitiendo concluir de forma descriptiva sobre relaciones entre variables, el mejor manejo de los datos.

3.4. Aspectos administrativos

La realización de la investigación será planificada según lo establecido en el siguiente diagrama:

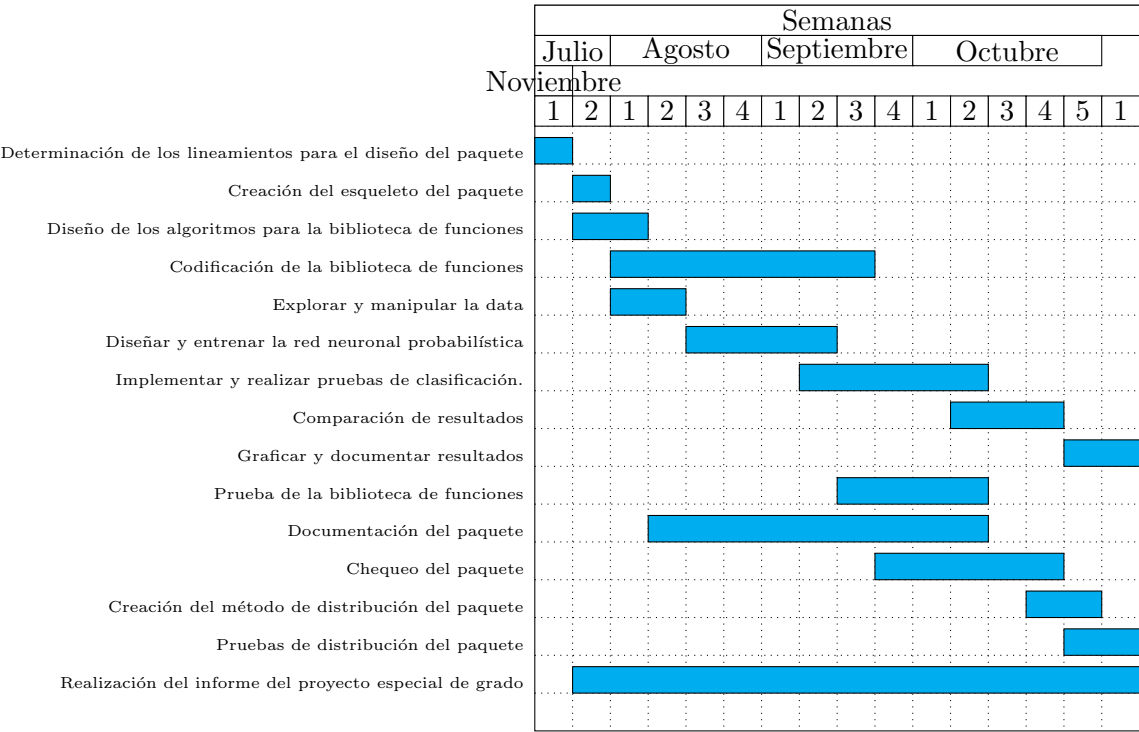


Figura 3.1: Diagrama de Gantt con la planificación del proyecto especial de grado

Referencias Bibliográficas

Available CRAN Packages By Name. Disponible en:https://cran.r-project.org/web/packages/available_packages_by_name.html. Consultada Junio 2018.

Lantz, B.(2015).«Machine Learning with R». Reino Unido: Packt Publishing Ltd.

Afshin, A., Abbaspour-Gilandeh, Y., Nooshyar, M., Afkari-Sayah, A. (2016). «Identifying Potato Varieties Using Machine Vision and Artificial Neural Networks». International Journal of Food Properties, Vol 19(3), pp. 618-635.

Stephen, W., Forrest, B., Eric, X., Yu-Xuan, W., Yi-Fan, C., Qiao-Liang, X. (2007). «A Leaf Recognition Algorithm for Plant Classification Using Probabilistic Neural Network». IEEE International Symposium on Signal Processing and Information Technology.

Nur Badariah, A., Kumutha, A., Syed, A., Zainul, A. (2011). «Classification of Fruits using Probabilistic Neural Networks - Improvement using Color Features». TENCON IEEE Region 10 Conference.

Bernal, N., Darghan, AE., Rodríguez, LE. (2017). «Modelado del Calibre de tubérculos de papa Solanum phureja bajo diferentes densidades de siembra mediante regresión binomial negativa cero-inflada».

Acevedo, I., Velásquez, E. (2008).«Algunos conceptos de la econometría espacial y el análisis exploratorio de datos espaciales». Ecos de Economía, No. 27, pp. 9-34.

Wiley, J. (2016). «R Deep Learning Essentials». Reino Unido: Packt Publishing Ltd.

Arias, V., Bustos, P., Ñustéz, C. (1996). «Evaluación del Rendimiento en papa criolla (*Solanum phureja*) variedad “Yema de Huevo”, bajo diferentes Densidades de Siembra en la Sabana de Bogotá.» *Agronomía Colombiana*, Vol. XIII, No 2, pp. 152-161.

Salomón, J., Estévez, A., Castillo, J., Cordero, M., Varela, M. (2009). «ESTUDIO DE LA COMPOSICIÓN DE CALIBRES EN VARIEDADES DE PAPA (*Solanum tuberosum*, L.) PARA LA PRODUCCIÓN NACIONAL DE TUBÉRCULOS-SEMILLA». *Cultivos Tropicales*, vol. 30, No. 1, pp. 69-72.

Cotes, J., Ñustez, C., Pachón, J. (2000). «EVALUACION DE LA DENSIDAD DE SIEMBRA Y EL TAMAÑO DEL TUBERCULO SEMILLA EN LA PRODUCCION DE SEMILLA BASICA DE PAPA CRIOLLA, VARIEDAD «YEMA DE HUEVO» (*Solanum phureja* Juz. et Buk.)». *Agro-nomía Colombiana*, No. 17, pp. 57-57.

Piñeros, C. (2009). «Recopilación de la Investigación del Sistema Productivo Papa Criolla». Secretaría de Agricultura y Desarrollo Economico (Gobernación de Cundinamarca), Federación Colombiana de Productos de Papa.

Buitrago, G., López, A., Coronado, A., Osorno, F. (2004). «Determinación de las características físicas y propiedades mecánicas de papa cultivada en Colombia». *Revista Brasileira de Engenharia Agrícola e Ambiental*, Vol.8, No.1, pp.102-110.

Ligarreto, G., Suárez, M. (2003). «EVALUACION DEL POTENCIAL DE LOS RECURSOS GENETICOS DE PAPA CRIOLLA (*Solanum phureja*) POR CALIDAD INDUSTRIAL». *Agronomía Colombiana*, Vol. 21, No. (1-2), pp. 83-94.

Patel, J., Seung-Kyum, C. (2012). «Classification approach for reliability-based topology optimization using probabilistic neural networks». *Struct Multidisc Optim*, No. 45, pp. 529–543.

Benavides, A. «Curvas ROC (Receiver-Operating-Characteristic) y sus aplicaciones». Universidad de Sevilla.